Processamento e Análise de Sinais Biomédicos

Prática I – Análise Espectral Visando à Construção de Interfaces Cérebro Máquina

Prof. Diogo Soriano

Uma interface cérebro-computador (BCI, do inglês *Brain-Computer Interface*) consiste em um dispositivo que capta sinais cerebrais e os mapeia em comandos para controle de dispositivos externos. Tais dispositivos têm como um dos seus principais propósitos auxiliar a comunicação de pessoas com severo comprometimento motor ou de comunicação, tais como observado após acidente vascular cerebral, lesão medular grave ou mesmo doenças neurodegerativas (esclerose amiotrófica lateral).

Dentre as principais modalidades de aquisição na construção de sistemas BCI, destaca-se a eletroencefalografia (EEG). Tal modalidade possui boa resolução temporal, não é invasiva e é passível de implementação com custo relativamente baixo. Dentre os protocolos experimentais mais utilizados em sistemas BCI baseados em EEG, destacam-se os potenciais evocados relacionados a eventos (P300), a imagética de tarefas e os potencias visualmente evocados em regime estacionário (SSVEP, do inglês *steady state visually evoked potentials*). Este último consiste em *grids* oscilando em diferentes frequências, estímulo visual esse que evoca uma sincronização da atividade elétrica no córtex visual, localizado na região occipital. Neste caso, cada frequência associada a um *grid* oscilante na interface associa-se com uma classe ou comando que se deseja executar (e.g. deslocamento do carro em um dado trajeto), sendo que a modulação da atenção do usuário em relação aos diferentes *grids* oscilantes permite a correta associação com o comando desejado.



Figura: Típica interfaces SSVEP. Fonte: P. Martinez, H. Bakardjian, A. Cichocki, "Fully Online Multicommand Brain-Computer Interface with Neurofeedback Using SSVEP Paradigm", Computational Intelligence and Neuroscience, ArticleID: 94561.

Em essência, a decodificação do comando na interface SSVEP pode ser feita por meio de uma análise de espectro dos eletrodos de EEG situados na região do córtex occipital. Nesta, a detecção dos picos em frequência correspondente a cada um dos diferentes estímulos visuais a qual o usuário se atém permite a correta associação com os comandos desejados. No entanto, como todos os estímulos são apresentados ao mesmo tempo, interferências associadas a estímulos capturados pela visão periférica, não linearidades da resposta em frequência do córtex visual, dentre outros problemas podem dificultar o processo de detecção.

Visando empregar de maneira prática os conceitos abordados de estimação de espectro, esse laboratório de processamento de sinais tem por objetivo implementar e investigar o comportamento de técnicas de estimação de espectro em sinais coletados no contexto de interfaces cérebro-computador baseadas no paradigma SSVEP.

Tendo isso em vista, carregue os sinais de EEG de um típico experimento de SSVEP presente no repositório ('S03.mat'). Neste arquivo tem-se um vetor *label* que indica a qual estímulo o usuário foca a sua atenção (1 – estímulo visual oscilando a 10 Hz; 2 – 11 Hz; 3 – 12 Hz; 4 – 13 Hz), sendo que o experimento foi repetido 48 vezes (*trials*). O arquivo 'Info.txt' indica a posição dos eletrodos e a figura 2, ilustra a posição desses eletrodos no escalpo. Os registros de EEG (*stimuliData*) consistem em uma matriz de 1536 amostras x 16 canais x 48 repetições.

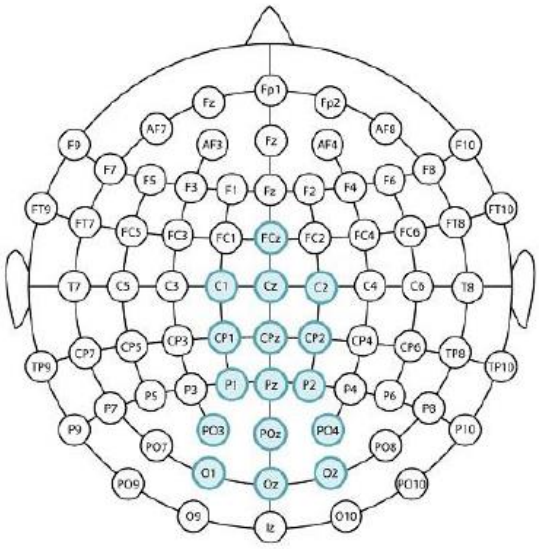


Figura 2: distribuição dos eletrodos no escalpo.

Tendo em vista esse experimento:

1) Crie uma função que calcula o espectro de magnitude de lado único (*single-sided amplitude spectrum*), recebendo o sinal no tempo (Sinal), a frequência de amostragem (fs), o número de pontos desejado para a FFT (NFFT) e um parâmetro que possibilita a opção de plotar ou não o espectro de magnitude (grafico). A função deve retornar a magnitude (Ymag), a fase (Yangle) e o respectivo vetor em frequência (FreqVect). Utilize a forma: [Ymag, Yangle, FreqVect] = EspectAnalysis(Sinal,Fs,NFFT,grafico). Pode-se utilizar a função FFT do próprio Matlab/Octave nesta implementação. **Nota**: o *single-sided amplitude spectrum* mostra toda a energia do espectro concentrado apenas nas frequências de 0 a fs/2. Pode ser implementado calculando o *double-sided spectrum* e multiplicando por 2 a magnitude dos coeficientes no intervalo (0,fs/2], i.e. todos os coeficientes em frequência com exceção do valor DC (f = 0). Dica: olhar *help fft* disponível na biblioteca ***online*** do Matlab;

2) Analise os espectros dos sinais de EEG e tente verificar se o pico em frequência corresponde à frequência a qual o usuário foca a sua atenção. Tente escolher eletrodos na região occipital para sua análise (tente o POz). Plote o espectro de

magnitude das realizações experimentais 1 e 2 assumindo o número de pontos da FFT (NFFT) como sendo 2048. Qual resolução de espectro neste caso? Tendo em vista os estímulos para o qual o voluntário se dirige em cada uma das situações (realização 1 e 2, por exemplo), o que se pode dizer do processo de atribuição de um rótulo (i.e. valores 1, 2, 3 ou 4 visando acertar a categoria do estímulo tal como dado pelo vetor 'label')?

3) Faça uma função denominada SlidingWindow que permita "fatiar" seu sinal no tempo em termos de uma janela deslizante, i.e. receber um vetor no tempo ('Data'), um escalar que define o tamanho de cada janela ('NwindowPoints') e um escalar que define o deslocamento inicial do início da janela ('shift'). A função deve retornar uma matriz ('DataWin') com 'NwindowPoints' amostras (linhas de 'DataWin') por N janelas (colunas de 'DataWin') do sinal de entrada 'Data' devidamente deslocadas segundo os parâmetros definidos. A função deve retornar também o vetor 'inipoint' contendo os índices de início de cada janela, o vetor 'endpoint' contendo o índice de fim de cada janela e o vetor center contendo o índice do centro de cada janela dado pelo valor arredondado para cima (função 'ceil') da mediana dos índices da janela (função 'median'). A função deve assumir a forma: [DataWin,inipoint, endpoint, center] = SlidingWindow(Data, NwindowPoints, shift). Caso 'Data' seja menor que 'NwindowPoints', 'DataWin' deverá ter apenas uma janela completando com zeros os valores nos índices faltantes até atingir tamanho 'NwindowPoints'. O mesmo procedimento deve ser adotado no caso da última janela quando o número de amostras restantes é inferior ao tamanho desejado da janela 'NwindowPoints'.

4) Utilizando as funções EspectAnalysis e SlidingWindow implemente o periodograma de Welch utilizando janela de Hamming (pode-se utilizar a função 'hamming' do Matlab ou implementar uma função com a expressão vista em aula), tamanho de janela NwindowPoints' = 512 e sobreposição de 50 % ('shift' = 256). Plote o Espectro de potência dado pelo periodograma. O que se pode afirmar em relação ao espectro de magnitude do item 1 em relação ao observado no periodograma? Use janela retangular e plote novamente o espectro de potência. O que se pode afirmar em relação a este espectro frente ao anterior? A janela retangular parece melhor ou pior para identificar o estímulo para o qual usuário modula sua atenção na primeira realização (trial =1).

5) (**<u>Para quem tem acesso ao Matlab – item não obrigatório</u>**) Acesse o help do Matlab e verifique o uso da função pwelch. Utilizando janelas de 512 pontos ('NpontosJanela'), sobreposição de 256 pontos ('NpontosSobreposição') e NFFT de 2048, compare os resultados do cálculo da função pwelch com os obtidos no item 4 utilizando janela de Hamming. A chamada da função pwelch é dada por: [pxx,f] = pwelch('vetordados', NpontosJanela, NpontosSobreposição, NFFT, fs). Neste caso, basta plotar f por Pxx e realizar a comparação solicitada. **Nota**: observe que a função pwelch retorna o cálculo da densidade espectral de potência baseado no *double-sided spectrum*. Tendo isso em vista, despreze possíveis diferenças de escalas entre os espectros de potência na comparação solicitada.

6) Faça um laço que percorra todas as realizações e identifique para as frequências de estimulação (ou nas proximidades destas), f = [10 11 12 13] Hz, qual dentre elas possui maior densidade espectral de potência. Baseado nesta comparação, construa um vetor ‘labelhat’ (48 linhas por 1 coluna) que atribui para cada realização uma ‘classe’, sendo essa de valor 1 caso o coeficiente de 10 Hz seja o maior dentre todos, 2 caso o coeficiente de 11 Hz seja o maior, 3 caso seja o de 12 e 4 caso seja o de 13. Ao final deste laço calcule a taxa de acerto comparando a “classe” estimada em ‘labelhat’ com a “classe” de fato contida no vetor ‘label’. A taxa de acerto é dada por: taxaacerto = 1 - (sum(labelhat ~= label)/length(label));

7) Implemente um código que percorra todos as realizações (trials) de todos os eletrodos e estime a taxa de acerto para cada um deles (eletrodos). Responda: a) Qual canal (eletrodo) leva ao melhor desempenho de classificação do estímulo? b) Qual janela leva ao melhor desempenho de classificação do estímulo (retangulares ou de Hamming)? Na sua resposta, tome como critério o desempenho de pico considerando todos os eletrodos. Mantendo uma sobreposição de 50 % em todos os cenários, como o desempenho de pico varia para NFFT = 256, NFFT = 512, NFFT = 1024, NFFT = 2048? O que se pode dizer em termos do compromisso número de janelas por resolução espectral neste caso?